

Rapport - Module M3 Segmentation Client

Rôle : Person 2 - Clustering Data Scientist **Projet :** marketing.optimization **Livrable associé :** data/processed/customer_segments.csv

1. Objectif

L'objectif de ce module est de regrouper mathématiquement les clients en un petit nombre de segments homogènes, à partir de leur comportement d'achat réel (dépense, fréquence, diversité des catégories achetées), sans a priori ni découpage manuel. Ces segments servent de socle technique au reste du projet : ils alimentent directement le profilage des personas (Person 3), le modèle de prédiction de churn/CLV (Person 5) et le dashboard final (Person 6).

2. Données utilisées

Fichier	Produit par	Rôle
customers_clean.csv	Person 1	Informations démographiques (Âge, Genre, Localisation...)
sales_clean.csv	Person 1	Historique des achats (montant, quantité, canal)
products_clean.csv	Person 1	Catégorie des produits achetés

Le jeu de données fourni pour ce projet est un **échantillon pédagogique réduit** (5 clients), confirmé comme tel par le professeur. Les résultats présentés ci-dessous sont donc **illustratifs et méthodologiquement complets**, mais pas statistiquement généralisables , ils valident que le pipeline fonctionne de bout en bout.

3. Méthodologie

3.1 Construction de la table de features

À partir de la jointure `sales_clean + products_clean + customers_clean` , une ligne par client a été construite avec les variables suivantes :

- Age
- Total_Spent : dépense totale
- Nb_Purchases : nombre d'achats
- Avg_Basket : panier moyen ($\text{Total_Spent} / \text{Nb_Purchases}$)
- Nb_Distinct_Categories : diversité des catégories achetées

3.2 Préparation et réduction de dimension

- **Standardisation** (`StandardScaler`) des variables, indispensable avant K-means car `Age` et `Total_Spent` n'ont pas la même échelle.
- **PCA** à 2 composantes pour la visualisation, expliquant **95,5 %** de la variance totale (PC1 = 59,8 %, PC2 = 35,7 %).
- **t-SNE** en projection complémentaire (non utilisée pour le clustering final).

3.3 Détermination du nombre de clusters

Deux méthodes combinées, testées sur la plage de k possible compte tenu de la taille de l'échantillon :

- **Méthode du coude** (inertie K-means)
- **Score de silhouette**

k	Score de silhouette
2	0,255
3	0,153

Choix retenu : k = 3. Le score de silhouette favorise légèrement k = 2, mais k = 3 a été retenu car il s'agit de la limite haute permise par l'échantillon et il laisse plus de matière à l'analyse des personas (Person 3). Ce choix est pragmatique plutôt que statistiquement tranché à refaire sur le jeu de données complet avec un k testé de 2 à 8.

3.4 Clustering

- **K-means** (k = 3, `n_init=10`) comme méthode principale.
- **Clustering hiérarchique** (linkage `ward`) appliqué en comparaison : les deux méthodes convergent parfaitement sur les mêmes regroupements de clients, ce qui valide la stabilité des groupes trouvés.

4. Résultats

Cluster	Taille	Profil
0	2 clients (50 %)	Clients occasionnels peu engagés : 1 seul achat, dépense faible
1	1 client (25 %)	Client jeune, achat ponctuel à panier élevé

Cluster	Taille	Profil
2	1 client (25 %)	Client le plus actif : achats répétés, catégories diversifiées, forte ancienneté

Score de silhouette final (k=3) : 0,153

5. Limites

- Échantillon très réduit (5 clients, dont 4 avec historique d'achat) : les résultats ne permettent pas de conclusion marketing exploitable en l'état.
- `Tenure_days` manquant dans les données livrées, réduisant la table de features à 5 variables au lieu de 6 prévues par la méthodologie initiale.
- À refaire intégralement sur le jeu de données complet dès qu'il sera disponible, avec la même méthodologie.

6. Livrables produits

- `notebooks/02_segmentation.ipynb` : notebook commenté et exécuté de bout en bout
- `data/processed/customer_segments.csv` : contrat : `Customer_ID`, `Cluster`, `PC1`, `PC2` (+ features)
- `notebooks/kmeans_model.pkl`, `scaler.pkl`, `pca_model.pkl` : modèles sauvegardés pour réutilisation

7. Outils utilisés

Python, pandas, scikit-learn (`StandardScaler` , `PCA` , `KMeans` , `AgglomerativeClustering` , `silhouette_score` , `TSNE`), scipy (`dendrogram` , `linkage`), matplotlib, seaborn, joblib.